TRƯỜNG ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

Multi-Agent Systems & Collaborative Reasoning

Khảo sát, phân tích và đánh giá 8 nghiên cứu năm 2026

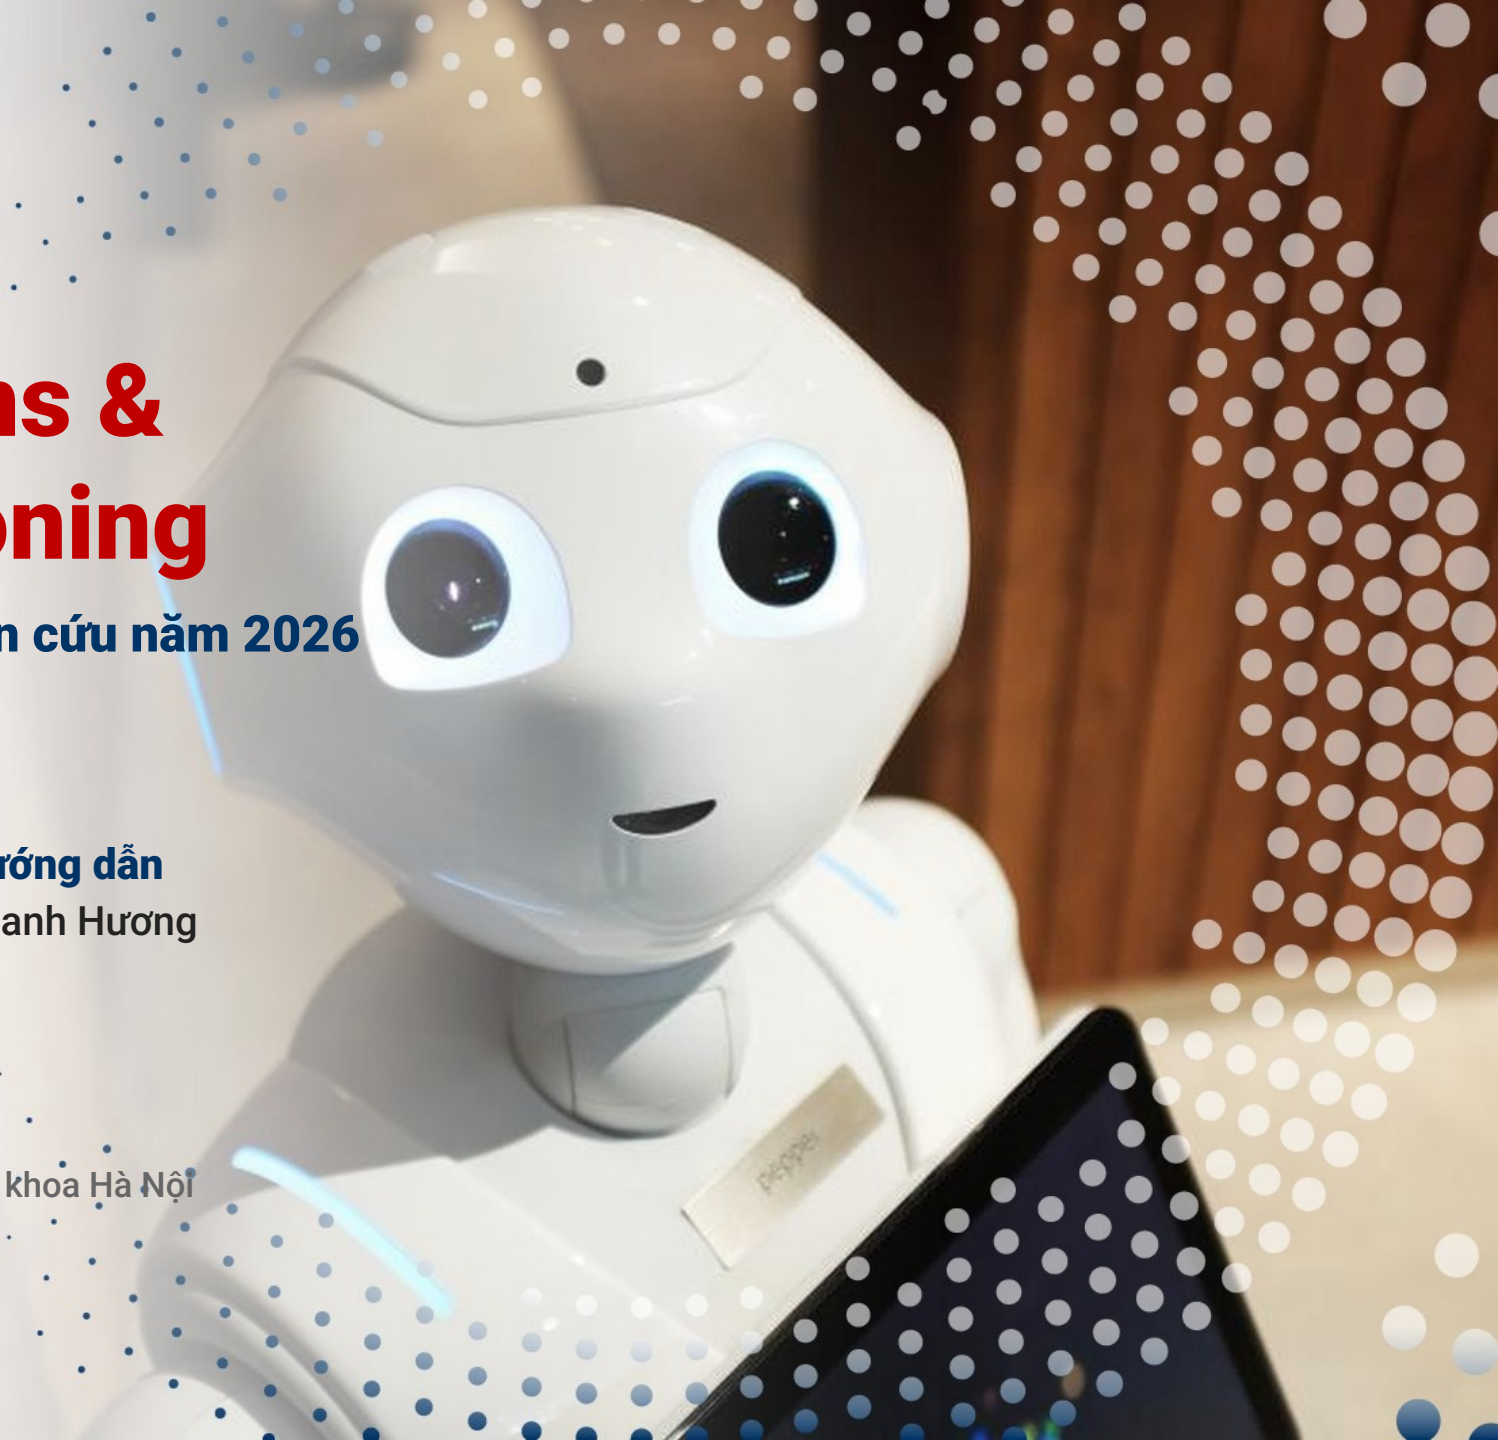
Báo cáo Bài tập lớn · Hình thức tiểu luận · Chủ đề số 3

Nhóm thực hiện
Trần Xuân Hương
Vũ Tùng Dương
Phạm Việt Dũng
Lê Văn Đức

Giảng viên hướng dẫn
PGS.TS. Lê Thanh Hương

Học phần IT4772 – Xử lý ngôn ngữ tự nhiên · Đại học Bách khoa Hà Nội

ONE LOVE. ONE FUTURE.



Nội dung trình bày

1 **Giới thiệu**
Bối cảnh, 4 thách thức, cách chọn 8 paper, taxonomy

2 **Safety & Robustness**
MIRAGE · TIDE

3 **Orchestration & Control**
ProgRouter · HalluProp

4 **Communication & Interaction**
DAIN · AGENT-RADAR

5 **Domain Applications**
MAC-RRG · UrbanAgent

6 **So sánh & kết luận**
So sánh hệ thống, research gap, hướng phát triển

TRƯỜNG ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

01

PHẦN 1

Giới thiệu

1. LLM-based Multi-Agent System
2. Bốn thách thức chính
3. Cách chọn 8 paper
4. Taxonomy bốn hướng nghiên cứu

ONE LOVE. ONE FUTURE.

LLM-based MAS: nhiều agent cùng suy luận

Ý tưởng

- Mỗi **agent** = backbone LLM + role prompt + (tùy chọn) tool.
- Các agent trao đổi message để cùng giải bài toán: planner, coder, critic, verifier…
- Framework tiêu biểu: CAMEL, AutoGen, MetaGPT, multi-agent debate.

Câu hỏi nghiên cứu năm 2026

- Không còn là "cộng tác có giúp không?" mà là:
- **hiệu quả** chi phí · **luồng thông tin** · **an toàn** · **ứng dụng** chuyên ngành.

MAS = communication graph

Node là agent; cạnh $v_j \rightarrow v_i$ nghĩa là output của v_j làm context cho v_i.

$$r_i = \text{LLM}(p_i, q, O_i)$$

Topology quyết định hiệu năng → có thể tối ưu (GPTSwarm, G-Designer) hoặc cắt tỉa (AgentPrune).

Vì sao topology quan trọng?

Nó vừa là đòn bẩy hiệu năng, vừa là kênh lan truyền lỗi, vừa là bề mặt tấn công.

Bốn thách thức chính của MAS

C1

Chi phí

Nhiều lần gọi LLM, context dài → token, năng lượng GPU, latency tăng nhanh.

→ **ProgRouter · DAIN**

C2

Quá tải context

"Lost in the middle"; compaction hay pruning đều làm mất thông tin.

→ **AGENT-RADAR**

C3

Lan truyền lỗi

Hallucination hoặc misinformation lan theo cạnh và bị khuếch đại.

→ **HalluProp · TIDE**

C4

Bảo mật topology

Topology là tài sản trí tuệ; lộ topology → tấn công có chủ đích.

→ **MIRAGE**

Tám paper được khảo sát

#	Paper	Chủ đề chính	Nộp	Nhóm
1	MIRAGE	Che giấu topology bằng phantom structure	29/09	Safety
2	MAC-RRG	Multi-agent cho radiology report generation	20/09	Application
3	ProgRouter	Routing LLM theo tiến độ, có ngân sách	26/08	Orchestration
4	TIDE	Misinformation khi sự thật bị phân tán	04/08	Safety
5	HalluProp	Dự báo rủi ro hallucination pre-hoc	29/07	Orchestration
6	UrbanAgent	Urban region profiling (KDD'26)	15/07	Application
7	DAIN	Dynamic agent interaction network	29/06	Communication
8	AGENT-RADAR	Attention steering cho MAS	28/05	Communication

Cách chọn bài

- Nguồn: **arXiv**.
- Abstract chứa "multi-agent" và "collaborative reasoning".
- Lấy **8 bài mới nhất** (05–09/2026).

Lưu ý

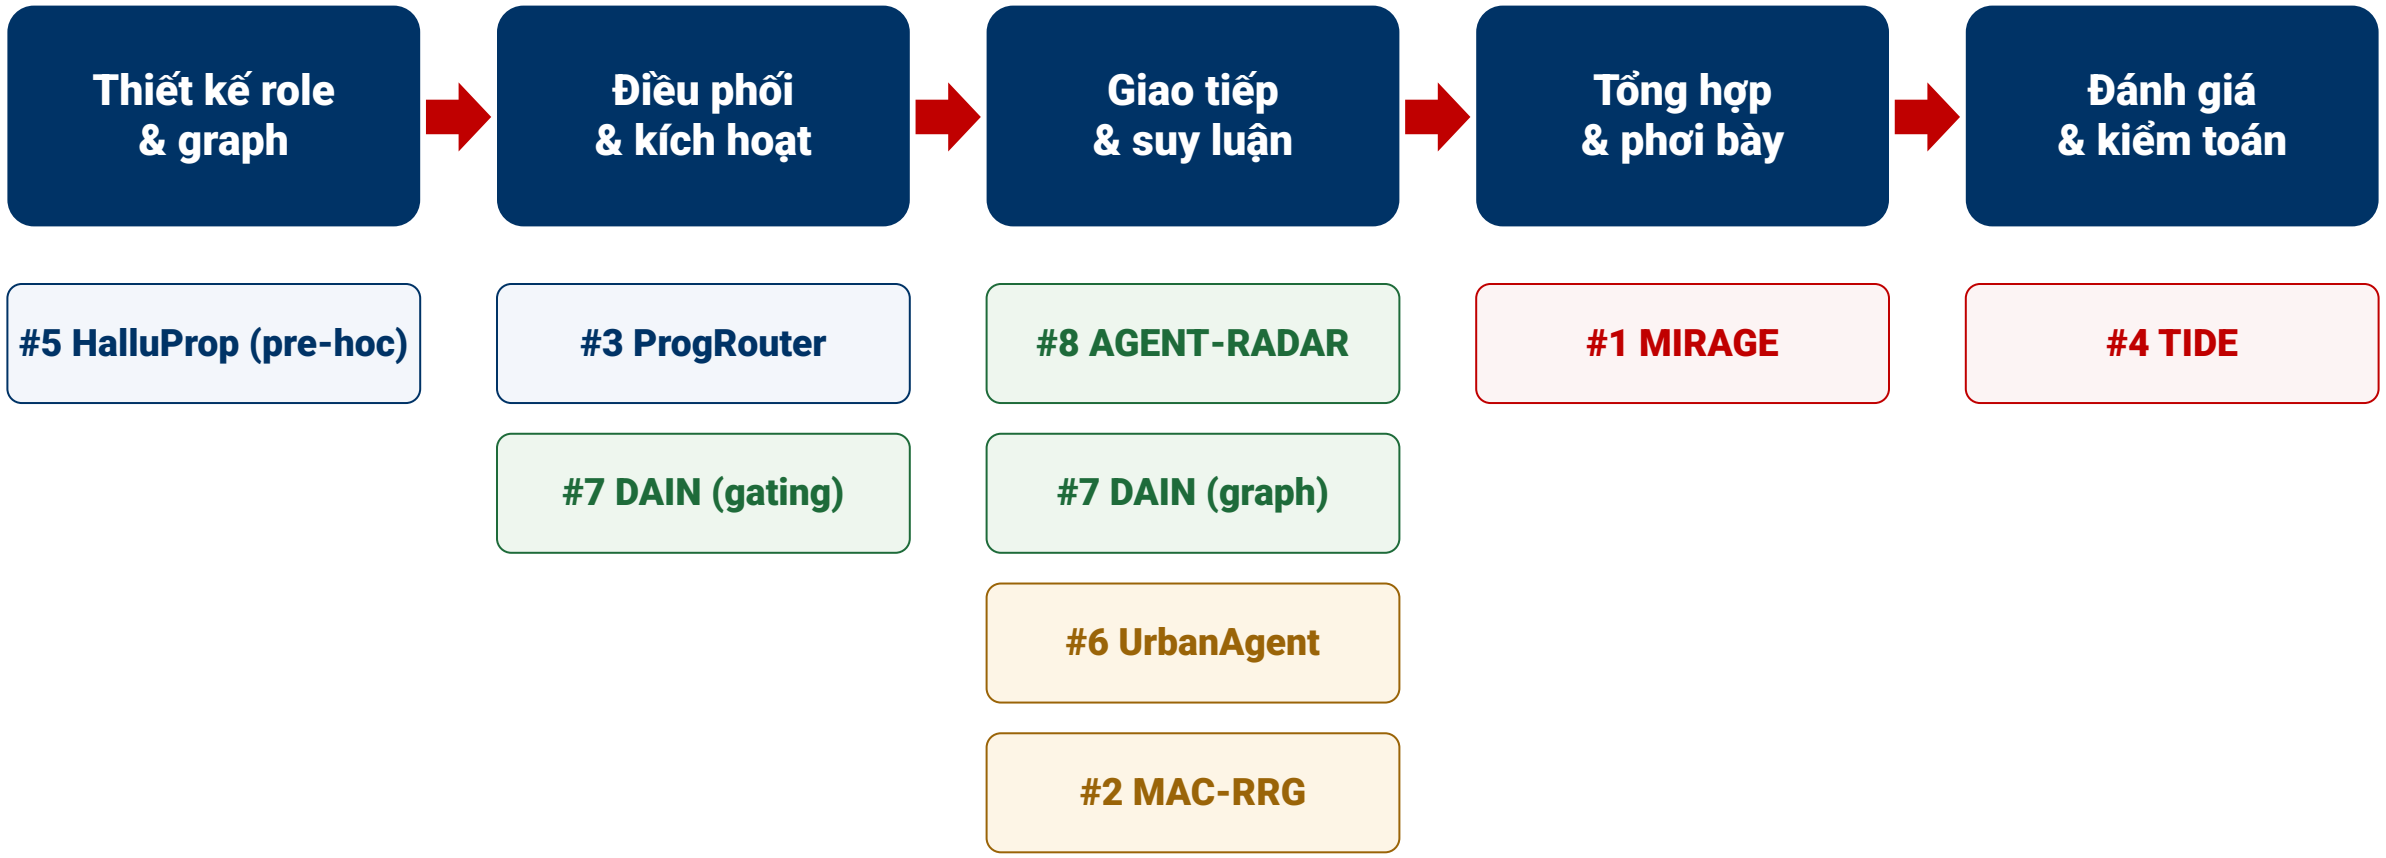
- **7/8** là preprint; chỉ UrbanAgent đã được nhận ở KDD 2026.

Taxonomy: bốn hướng nghiên cứu

Safety & Robustness	Orchestration & Control	Communication & Interaction	Domain Applications
Câu hỏi chính	Câu hỏi chính	Câu hỏi chính	Câu hỏi chính
Hệ thống có chống chịu được tấn công và thông tin sai?	Ai chạy, chạy bằng model nào, agent nào rủi ro?	Agent trao đổi gì, với ai, mức độ nào?	Áp dụng cộng tác vào bài toán chuyên ngành.
#1 MIRAGE	#3 ProgRouter	#7 DAIN	#2 MAC-RRG
#4 TIDE	#5 HalluProp	#8 AGENT-RADAR	#6 UrbanAgent

Phân loại theo **mục tiêu chính**; nhiều bài thuộc nhiều nhóm (VD: HalluProp vừa là orchestration vừa là safety).

Mỗi phương pháp can thiệp ở đâu trong lifecycle của MAS



Màu: **đỏ** Safety · **xanh navy** Orchestration · xanh lá Communication · vàng Application

TRƯỜNG ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY



02

PHẦN 2

Safety & Robustness

1. MIRAGE: che giấu topology của MAS
2. TIDE: misinformation khi sự thật bị phân tán

ONE LOVE. ONE FUTURE.

MIRAGE: che giấu topology bằng phantom structure

Bài toán

- Tấn công **CIA** suy ra topology chỉ qua truy vấn hộp đen.
- Lộ topology → mất tài sản trí tuệ, lộ agent then chốt.

Phương pháp: 3 bước

- **Phantom topology:** đi dây lại cạnh, độ lệch $\rho \geq \rho_0$ (k-anonymity).
- **Semantic edge realization:** LLM sinh bằng chứng giả cho phantom edge; paraphrase để giấu cạnh thật.
- **Dual-view execution:** chạy trên G thật, chỉ phơi bày G'.

AUC / ACC / F1 của tấn công (G-Designer, thấp hơn là tốt)

Dataset	Delimiters	MIRAGE
MMLU	0.76 / 0.61 / 0.64	**0.67 / 0.50 / 0.49**
GSM8K	0.80 / 0.76 / 0.67	**0.64 / 0.51 / 0.42**
SVAMP	0.70 / 0.68 / 0.71	**0.64 / 0.48 / 0.39**
HumanEval	0.76 / 0.65 / 0.56	**0.68 / 0.44** / 0.52

Hạn chế

- Chỉ 1 tấn công, không có adaptive attacker.
- AUC vẫn 0.64–0.68, xa mức lý tưởng 0.5.
- Không báo cáo chi phí của các lần gọi LLM thêm.

TIDE: misinformation làm chệch collective fact recovery

Thiết lập

- **120 môi trường** Hi-ToM; 5 agent, mỗi agent chỉ thấy một phần chuỗi vị trí.
- C0: tất cả trung thực · C1: key agent nói dối (Event / Coverage / Source).
- GPT-5.5, DeepSeek-v4-pro, Grok-4.5; đo cả **evidence lineage**.

Tỉ lệ đa số đúng (C0 → C1)

72.50% → 14.17%

70.7% vs 25.4%

testimony sai vs đúng được chấp nhận

2.66 vs 1.33

propagation order: sai vs đúng

Thông điệp

- Thảo luận **khuếch đại** chiều hướng của bằng chứng ban đầu thay vì sửa sai; ~85% khoảng cách hình thành ngay khi chia sẻ testimony.
- Observer giảm 90% decoy majority nhưng **không** tăng đáp án đúng. Hạn chế: 1 tác vụ hẹp, chưa có defense.

TRƯỜNG ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY



03

PHẦN 3

Orchestration & Control

1. ProgRouter: routing LLM theo tiến độ
2. HalluProp: dự báo rủi ro trước khi chạy

ONE LOVE. ONE FUTURE.

ProgRouter: chọn LLM cho từng bước của workflow

Bài toán

- Router cũ quyết định **1 lần/câu hỏi**; workflow cần quyết định **từng bước**.

Ba thành phần

- **Progress scorer** g(s_t) ∈ [0,1].
- **Predictor** hai nhánh + XGBoost meta-learner.
- **Lyapunov drift-plus-penalty** với ngân sách năng lượng.

Điểm định tuyến

score(m) = V·(1−g)·ŷ(m) − Q·(E(m)−Ē) − c_Γ·Γ(m) − c_E·E(m)

Tiến độ có giá trị hơn khi tác vụ còn xa đích.

Accuracy % / năng lượng J (in đỏ: vượt ngân sách)

Method	HumanEval+	MBPP	MATH-500
MasRouter	90.9 / 4483	67.8 / 3700	**73.6 / 8294**
CASCADIA	84.8 / 4658	78.5 / 3857	**87.8** / 6875
ProgRouter	**93.0** / 4796	**79.4 / 3376**	84.3 / **6112**

84.3%

lần gọi dùng model 0.5B (HumanEval+)

17.7%

accuracy của greedy “progress / cost” ngây thơ

Hạn chế: thua CASCADIA 3.5 điểm trên MATH-500; bỏ qua chi phí warm-up; mốc tiến độ phải định nghĩa thủ công.

HalluProp: dự báo rủi ro trước khi agent lên tiếng

Ý tưởng: pre-hoc

- Chỉ dùng **role prompt + câu hỏi + topology**, chưa chạy agent nào.
- **Intrinsic risk** π_i: role có khớp câu hỏi không.
- **Propagation risk** $t_{j\to i}$: ảnh hưởng của bên gửi × độ dễ tổn thương của bên nhận.
- Can thiệp: cắt cạnh ra hoặc đổi role thành verifier.

Noisy-OR khả vi (K = 3 vòng lặp)

$$h_i = 1 - (1 - \pi_i) \cdot \Pi_j (1 - t_{j\to i} \cdot h_j)$$

Agent lỗi nếu tự lỗi, hoặc nhận lỗi lan từ bất kỳ agent gửi tin nào.

84.6 — AUROC trung bình (4 LLM × 3 dataset)

< 1 s — chẩn đoán, so với 53–308 s của post-hoc

67.6% — accuracy sau refinement, so với 63.5% của GUARDIAN

Hạn chế

"Hallucination" = trả lời sai; role bị nhiễu nhân tạo; cần nhãn; đồ thị ≤ 7 agent.

TRƯỜNG ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

04

PHẦN 4

Communication & Interaction

1. DAIN: dynamic agent interaction network
2. AGENT-RADAR: attention steering

ONE LOVE. ONE FUTURE.

DAIN: Dynamic Agent-based Interaction Network

Encode	Meta-Controller	Message passing	Consensus
ResNet-50, BERT → context e_c	sparse gate + soft graph Φ	qua low-rank bottleneck	attention → kết quả

8 agent theo PID

- 3 **synergy** · 3 **uniqueness** · 2 **redundancy**.
- Loss phạt kích hoạt và mật độ giao tiếp: $\lambda\|g\|_1 + \lambda\|\Phi\|^2$.

3.2–5.5 / 8

agent được kích hoạt

73.5 vs 70.9

ADNI accuracy (best baseline)

Lưu ý khi đánh giá

- "Agent" là **neural module**, không phải LLM: bản chất là MoE có message passing.
- Bỏ communication: −1.4 điểm; bỏ dynamic scheduling: −1.7 điểm (ADNI).
- Số liệu không nhất quán giữa các bảng; baseline yếu.

AGENT-RADAR: attention steering theo context relevance

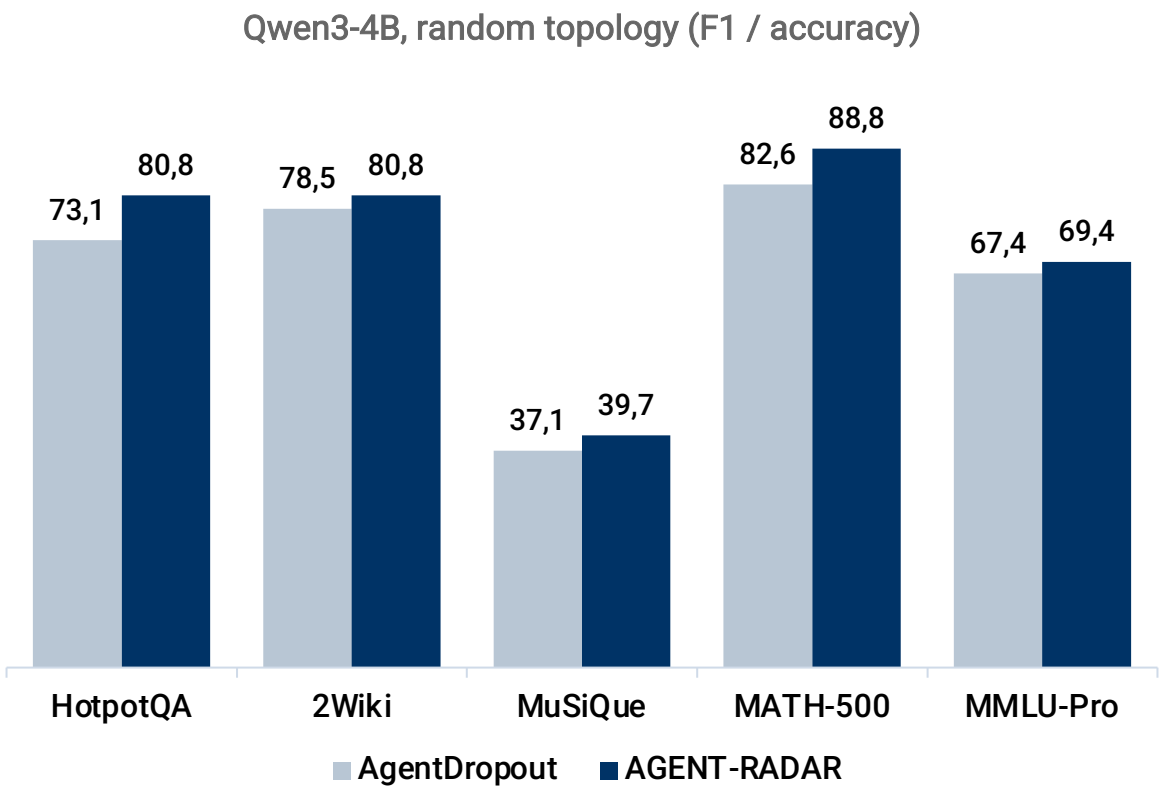
Ý tưởng

- Giữ **toàn bộ** lịch sử, không tóm tắt hay cắt bớt.
- Chấm điểm từng câu, câu ≥ θ = 0.65 được nhấn mạnh bằng **SPA**.
- Training-free, cắm được vào GPTSwarm, AutoGen, debate.

Điểm của câu s_k

$$\lambda_s^{(d_G - 1)} \times \lambda_t^{(t - \tau - 1)} \times \cos(s_k, q)$$

spatial decay × temporal decay × semantic relevance



Latency +23% · cần **white-box** (logit) → không dùng với API model · tune trên MuSiQue (cũng là test set).

TRƯỜNG ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY



05

PHẦN 5

Domain Applications

1. MAC-RRG: radiology report generation
2. UrbanAgent: urban region profiling

ONE LOVE. ONE FUTURE.

MAC-RRG: multi-agent cho radiology report generation



0.197 / 0.128 / 0.105

BLEU-4 trên IU X-Ray / MIMIC-CXR / CheXpert Plus

0.295 vs 0.260

clinical F1 (CheXpert Plus) so với R2GenGPT

Đánh giá phản biện

- "Agent" = **module retrieval tất định**, không giao tiếp hay thương lượng.
- "Iterative" thực tế chỉ **1 lượt** tinh chỉnh.
- BLEU tăng nhỏ (0.101 → 0.105); không kiểm định thống kê, không có bác sĩ đánh giá.

UrbanAgent: collaborative reasoning cho urban region profiling

Stage A · Tool-augmented agents

- 4 agent theo modality: **satellite, text, POI, 3D**.
- Qwen3-VL-4B + 4 tool (web search, crop-zoom, nightlight, ảnh lịch sử).
- SFT → **GRPO**, reward = outcome + format + process.

Stage B · Relation-aware graph

- **Corroboration**: dự đoán gần nhau → củng cố.
- **Rectification**: lệch nhiều → sửa.
- **Supervisory**: agent tự tin hơn hướng dẫn. 5 vòng GRU → final judge.

0.63–0.65

R^2 trong miền (carbon, dân số, GDP)

≈ 0.60

R^2 trên thành phố chưa thấy

+8.1%

R^2 trung bình so với baseline mạnh nhất

Đánh giá phản biện

- "Debate" là **GNN/GRU được huấn luyện**, không phải tranh luận bằng ngôn ngữ.
- Dữ liệu nhỏ (2,000 vị trí); text sinh từ chính ảnh vệ tinh → các modality không độc lập.

TRƯỜNG ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY



06

PHẦN 6

So sánh & kết luận

1. So sánh hệ thống 8 paper
2. Ba nhận định xuyên suốt
3. Research gap và hướng phát triển
4. Kết luận

ONE LOVE. ONE FUTURE.

So sánh hệ thống tám paper

Paper	Loại đóng góp	Training	White-box	Chi phí	Thống kê
MIRAGE	Defense	✗	✗	✗	✗
TIDE	Benchmark	✗	✗	✗	✓
ProgRouter	Router	online	✗	✓ **năng lượng**	✗
HalluProp	Risk predictor	✓	✗	~ thời gian	✗
DAIN	Kiến trúc fusion	✓	–	~ tham số	✗
AGENT-RADAR	Plug-in	✗	✓	~ thời gian	✗
MAC-RRG	Ứng dụng	✓	–	✗	✗
UrbanAgent	Ứng dụng	✓	–	✗	✗

Đọc bảng

- Chỉ **TIDE** có kiểm định thống kê.
- Chỉ **ProgRouter** đo năng lượng GPU thực.
- Chỉ **AGENT-RADAR** bắt buộc white-box.
- Cùng benchmark nhưng khác tập con, topology, backbone → **không so trực tiếp** được con số.

Ba nhận định xuyên suốt

1

Communication graph là trung tâm

6/8 bài thao tác trực tiếp: **giấu** (MIRAGE), **phân tích** (HalluProp), **đo khoảng cách** (RADAR), **học** (DAIN, UrbanAgent), **truy vết** (TIDE).

2

Lan truyền là rủi ro cốt lõi

Thảo luận **khuếch đại** sai lệch thay vì sửa sai (TIDE); hallucination lan theo cạnh (HalluProp).

3

Khái niệm "agent" bị nới rộng

LLM agent thật (5 bài) · LLM + aggregator học được (UrbanAgent) · neural / retrieval module (DAIN, MAC-RRG).

Hiệu quả **không** đến từ nhiều agent hơn: ProgRouter dùng chủ yếu model 0.5B; DAIN tốt nhất với $\tau = 4/8$ agent.

Research gap và hướng phát triển

Research gap

G1	Chưa có benchmark chung: chất lượng + chi phí + robustness
G2	7/8 bài không có phương sai hay kiểm định thống kê
G3	Quy mô nhỏ: ≤ 8 agent, 2–5 vòng, tác vụ ngắn
G4	Chưa có adaptive attacker; chưa có cách khôi phục sự thật
G5	Phương pháp tối ưu chưa được thử trong điều kiện đối kháng

Hướng phát triển

Benchmark 3 trục
chất lượng · chi phí · robustness (giao thức C0/C1 của TIDE)

Provenance-aware communication
score(RADAR) × (1 − ĥ_j) × μ^hop

Risk-aware routing
ProgRouter + HalluProp: bước rủi ro → model mạnh

Verifier agent chủ động
đòi bằng chứng trực tiếp trước khi đồng thuận

Kết luận

1 **Communication graph là trung tâm**
quyết định hiệu năng, lan truyền rủi ro, cần được bảo vệ

2 **Lan truyền là rủi ro cốt lõi**
thảo luận khuếch đại sai lệch thay vì sửa sai

3 **Hiệu quả = kích hoạt đúng**
đúng agent, đúng model, chú ý đúng nội dung

4 **Thực nghiệm còn yếu**
quy mô nhỏ, thiếu kiểm định, thiếu đo chi phí

Câu hỏi của lĩnh vực đang chuyển

Từ "nhiều agent có tốt hơn một agent?"
sang "làm sao để MAS **hiệu quả**, **đáng tin cậy** và **an toàn**?"

TRƯỜNG ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

Cảm ơn cô và các bạn

đã lắng nghe! · Q&A

Thành viên	Paper phụ trách
Trần Xuân Hương	MIRAGE · TIDE
Vũ Tùng Dương	ProgRouter · HalluProp
Phạm Việt Dũng	DAIN · AGENT-RADAR
Lê Văn Đức	MAC-RRG · UrbanAgent

Học phần IT4772 – Xử lý ngôn ngữ tự nhiên · Đại học Bách khoa Hà Nội

ONE LOVE. ONE FUTURE.